

PROYECTO ANALÍTICA:

ANÁLISIS DE PRODUCCIÓN AGRÍCOLA EN COLOMBIA

ACTIVIDAD DE APRENDIZAJE N°1

JUSTIN BECKHAN CARDONA

JORGE ARMANDO RODRIGUEZ

LINA JOHANA SEGURO GAVIRIA

FACULTAD DE INGENIERÍA Y CIENCIAS AGROPECUARIAS

INSTITUCIÓN UNIVERSITARIA DIGITAL DE ANTIOQUIA

046: PROYECTO INTEGRADO III_ANALÍTICA DE DATOS

ANDRÉS FELIPE PALACIO

26 DE ABRIL DEL 2026

Introducción

El presente proyecto tiene como objetivo analizar la producción agrícola en Colombia mediante el uso de técnicas de analítica de datos. A partir de un dataset obtenido del portal datos.gov.co, se busca identificar patrones y variaciones en la producción según el tipo de cultivo y la región.

Este análisis permite comprender mejor el comportamiento del sector agrícola, el cual es fundamental para la economía del país. Además, mediante el uso de herramientas como Google Colab y técnicas de exploración de datos, se pretende obtener información relevante que apoye la toma de decisiones y el desarrollo de futuros modelos predictivos.

Objetivos

Objetivo General:

Analizar la productividad agrícola en Colombia durante el periodo 2019–2024, mediante el uso del rendimiento (t/ha), para identificar las zonas de mayor eficiencia, tomando como caso de estudio el cultivo de café en la región andina.

Objetivos Específicos:

- Describir el dataset y sus variables principales.
- Identificar patrones en la producción agrícola.
- Analizar la relación entre área sembrada, producción y rendimiento.
- Detectar posibles problemas en los datos como valores nulos o duplicados.

Definición del problema de Negocio

Descripción del problema

La producción agrícola en Colombia presenta variaciones significativas entre diferentes regiones y tipos de cultivo. Estas diferencias pueden afectar la planificación y la toma de decisiones en el sector agro, ya que no se tiene claridad sobre qué cultivos son más productivos ni en qué zonas se obtienen mejores resultados.

Pregunta de investigación:

¿De qué manera varía el rendimiento agrícola (t/ha) en Colombia según el tipo de cultivo y la región en el periodo 2019–2024, y en qué medida el rendimiento del café en la región andina supera el promedio nacional de este cultivo?

Métricas de éxito:

Para evaluar el éxito del análisis se utilizarán las siguientes métricas:

- **Rendimiento agrícola (t/ha):** métrica principal de eficiencia productiva.

Se calcula como la relación entre la producción y el área cosechada:

$$\text{Rendimiento} = \frac{\text{Producción}}{\text{Área cosechada}}$$

El éxito del análisis se medirá mediante la identificación de los 5 departamentos con mayor rendimiento promedio, segmentados por tipo de cultivo.

- **Producción total (t) y área cosechada (ha):** variables base para el cálculo del rendimiento.
- **Promedio de rendimiento por departamento:** permite realizar comparaciones geográficas y segmentar según el tipo de cultivo.

Estas métricas permitirán identificar los departamentos con mayor eficiencia agrícola y analizar las diferencias en el comportamiento productivo según el tipo de cultivo.

Hipótesis

El rendimiento agrícola promedio (t/ha) del cultivo de café en los departamentos de la región andina es superior al promedio nacional para ese mismo cultivo durante el periodo 2019–2024.

Para este análisis, la región andina se definió como los departamentos de: Antioquia, Boyacá, Caldas, Cundinamarca, Huila, Norte de Santander, Quindío, Risaralda, Santander y Tolima.

Fuentes de Datos

Para este proyecto se utiliza el conjunto de datos de las Evaluaciones Agropecuarias Municipales (EVA), coordinado por la Unidad de Planificación Rural Agropecuaria (UPRA).

1. **Fuente:** Unidad de Planificación Rural Agropecuaria (UPRA) / Portal de Datos Abiertos de Colombia (datos.gov.co).

El dataset puede consultarse en el siguiente enlace: [Evaluaciones Agropecuarias Municipales \(EVA\)](#).

2. Formato y Tamaño:

- Formato: CSV.
- Tamaño del dataset: * Filas: 141,000 registros.
- Columnas: 18 variables.
- Cobertura Geográfica: Nacional (1.103 municipios).
- Periodo de tiempo: 2019 - 2024.
- Última actualización de datos: 21 de octubre de 2025 (Metadatos actualizados a diciembre de 2025).

3. Descripción de variables

Cada fila del dataset representa información de un cultivo específico en un municipio y periodo determinado. Las variables se agrupan en:

- Geográficas (categóricas): Departamento, Municipio, códigos DANE.
- Clasificación del cultivo (categóricas): Grupo, subgrupo, desagregación, ciclo del cultivo.
- Temporales: Año (numérica discreta) y periodo (categórica).
- Métricas agrícolas (numéricas): Área sembrada, área cosechada, producción y rendimiento. Aunque estas variables representan valores numéricos, en el dataset se encuentran almacenadas como tipo texto (object), por lo que requieren un proceso de conversión para su correcto análisis.
- Identificación del cultivo: Código del cultivo (numérico identificador) y nombre científico del cultivo (categórica).

- Tipos de Datos: El dataset contiene variables categóricas y numéricas. Se identifican 4 variables numéricas principales (área sembrada, área cosechada, producción y rendimiento) y 14 variables categóricas. Sin embargo, se evidencia que algunas variables numéricas están almacenadas como texto, lo que requiere procesos de limpieza para su adecuado análisis.

4. Diccionario de Datos

Variable	Tipo de dato	Descripción
Código Dane departamento	Numérico (int)	Código único del departamento según el DANE
Departamento	Categórica	Nombre del departamento
Código Dane municipio	Numérico (int)	Código único del municipio según el DANE
Municipio	Categórica	Nombre del municipio
Grupo cultivo	Categórica	Clasificación general del cultivo
Subgrupo	Categórica	Subcategoría del cultivo
Cultivo	Categórica	Nombre específico del cultivo
Desagregación cultivo	Categórica	Detalle adicional del cultivo
Año	Numérico (int)	Año del registro
Periodo	Categórica	Periodo de tiempo (generalmente anual o semestral)
Área sembrada	Numérico*	Área sembrada en hectáreas (requiere conversión)
Área cosechada	Numérico*	Área cosechada en hectáreas (requiere conversión)
Producción	Numérico*	Producción en toneladas (requiere conversión)
Rendimiento	Numérico*	Producción por hectárea (t/ha) (requiere conversión)
Ciclo del cultivo	Categórica	Tipo de ciclo (permanente o transitorio)
Estado físico del cultivo	Categórica	Estado del producto (ej. seco, fresco)
Código del cultivo	Numérico (int)	Identificador único del cultivo
Nombre científico del cultivo	Categórica	Nombre científico del cultivo

5. Granularidad

Los datos están registrados a nivel municipal y por periodo. Cada fila representa un cultivo específico en un municipio determinado durante un año y periodo, incluyendo información sobre producción, área y rendimiento.

6. Relevancia del dataset

Este dataset es relevante porque contiene información detallada sobre la producción agrícola en Colombia, permitiendo analizar el comportamiento del sector a nivel municipal y departamental. A través de variables como producción, área cosechada y rendimiento, es posible evaluar la eficiencia agrícola y apoyar la toma de decisiones en el sector agropecuario.

Planeación

Para la gestión del proyecto se utilizó la metodología ágil Kanban mediante la herramienta Trello. Esto permitió la asignación de tareas específicas, el seguimiento de los avances en tiempo real y la sincronización del equipo para cumplir con las fases de limpieza, exploración y documentación del análisis.

Tablero de control en el siguiente enlace: [Tablero de Trello - Gestión de Proyecto.](#)

Creación del Repositorio y Entorno de Trabajo

Para garantizar la transparencia, el control de versiones y la reproducibilidad del análisis, se creó un repositorio público en la plataforma GitHub.

- Plataforma: GitHub
- Herramienta de desarrollo: Google Colab (Notebook .ipynb)

- Gestión de versiones: Se realizaron commits periódicos para registrar los avances en la exploración, limpieza y análisis de los datos.
- README: El repositorio incluye un archivo README con la descripción del proyecto, objetivos, hipótesis y estructura del análisis.
- Colaboradores: Los integrantes del equipo fueron añadidos como colaboradores del repositorio para facilitar el trabajo conjunto.

Enlace al repositorio: [Repositorio de GitHub - Proyecto Integrado III](#)

Tareas de Limpieza de Datos

1. Conversión de variables numéricas almacenadas como texto (object) a tipo float, debido a formatos con comas decimales.
2. Estandarización de las variables de área, producción y rendimiento para su correcto análisis estadístico.
3. Identificación y tratamiento de variables redundantes, como Periodo, que contiene la misma información que Año.
4. Se identificaron valores de 0.00 en variables como área, producción y rendimiento, los cuales deben revisarse para asegurar la calidad del análisis.

Descripción de Necesidades de Limpieza

1. Valores Nulos

En la fase de depuración, se realizó una distinción crítica entre nulos técnicos y lógicos:

- **Nulos Técnicos:** Son celdas vacías (NaN) que el sistema detecta automáticamente. En este dataset, el reporte inicial indicó la ausencia de este tipo de vacíos.
- **Nulos Lógicos:** Son registros que contienen el valor **0.00**. Aunque para el software son números válidos, desde la lógica agronómica representan la ausencia de actividad productiva (áreas no cosechadas o pérdida total del cultivo).

Conclusiones:

- Estado: El dataset presenta una completitud del 100% en las variables críticas para el estudio.
- Justificación: Al no existir valores faltantes en las columnas de "Área Cosechada" y "Producción", el cálculo del Rendimiento (t/ha) será exacto para todos los municipios, eliminando la necesidad de técnicas de imputación (media/mediana).

1.2. Nulos Lógicos (*Ceros Estructurales*)

- Estado: Se identificaron **5,465 registros** con valor 0.00 en área, producción y rendimiento. Se determinó que mantener estos datos subestimaría artificialmente el rendimiento promedio nacional, ya que se estaría promediando la eficiencia de cultivos productivos con áreas que no entregaron fruto.
- Decisión Técnica: Para el cálculo del rendimiento real (t/ha), se aplicará un filtro para excluir estos 5,465 registros nulos, de los cuales **solo 36 correspondían al**

cultivo de café, garantizando así que los resultados reflejen la productividad efectiva de las hectáreas cosechadas.

2. Duplicados

- Estado: No se detectaron registros duplicados en el conjunto de datos (0 filas repetidas).
- Justificación: Se realizó la verificación técnica para garantizar la integridad de la información y asegurar que cada registro de producción municipal sea único, evitando inflar los totales de producción nacional.

3. Inconsistencias en Valores

- Observación: Se revisará la columna de departamentos y municipios buscando errores tipográficos, diferencias entre mayúsculas/minúsculas y uso de tildes (ej. "BOGOTA" vs "Bogotá").

3.1. Verificación de Inconsistencias en Departamentos

Se realiza un conteo de valores únicos y un listado alfabético para identificar posibles errores de escritura, duplicidad por tildes o variaciones en el uso de mayúsculas y minúsculas.

Conclusión de la verificación de departamentos:

- Estado: Limpio y Consistente.
- Hallazgo: El análisis de valores únicos arrojó exactamente 32 entidades, las cuales corresponden a la división política oficial de Colombia. No se detectaron

duplicados generados por errores de ortografía, tildes o inconsistencias entre mayúsculas y minúsculas (ej. "Antioquia" vs "ANTIOQUIA").

- Impacto: Este resultado garantiza que las agrupaciones regionales posteriores serán precisas y no requerirán correcciones manuales en esta columna específica.

3.2. Verificación de Inconsistencias en Municipios

Se utiliza el método `value_counts()` para observar la frecuencia de los nombres de los municipios. El objetivo es identificar visualmente posibles problemas de formato, espacios en blanco extra o nombres repetidos que podrían indicar una alta frecuencia de registros por municipio o la existencia de municipios homónimos en diferentes departamentos.

Conclusión de la verificación de municipios:

- Estado: Datos consistentes, pero con presencia de homónimos.
- Hallazgo: Se observa una alta frecuencia en nombres como "La Unión", "Bolívar" y "Granada". Al cruzar esta información, se confirma que no son errores de duplicidad, sino municipios diferentes que comparten el mismo nombre en distintos departamentos (por ejemplo, La Unión en Antioquia, Valle y Nariño).
- Impacto: Este hallazgo es fundamental para la fase de transformación. Indica que cualquier análisis o agrupación no debe hacerse exclusivamente por la columna Municipio, sino mediante una llave combinada (Departamento + Municipio) para evitar sesgos en las cifras de producción.

3.3. Validación de Municipios Homónimos

Dado que el conteo de frecuencias mostró nombres repetidos como "La Unión", se procede a verificar si estos registros corresponden a errores de duplicidad o si pertenecen a distintas entidades territoriales.

Conclusión de la verificación de municipios:

- **Importancia para el proyecto:** Aunque el análisis final se centra en la agrupación por Departamento para consolidar la Región Andina, esta validación fue crítica para asegurar la integridad de la base de datos y la veracidad de las cifras antes de cualquier proceso de limpieza.
- **Hallazgo:** Mediante el análisis de valores únicos, se confirmó que nombres como "La Unión" aparecen en múltiples ocasiones debido a que pertenecen a departamentos diferentes (como Antioquia, Nariño y Valle del Cauca).
- **Garantía técnica:** Esta verificación permitió determinar que no existen registros duplicados por error de captura, sino que se trata de municipios homónimos. Al identificar esto, se garantiza que no se elimine ninguna fila por error, protegiendo así el volumen total de producción y el área cosechada, datos que son vitales para no alterar los promedios regionales y nacionales en el informe final.

3.4. Verificación de la Variable Objetivo (Cultivo)

Dado que el análisis se centra exclusivamente en el Café, es vital identificar si el nombre del cultivo presenta variaciones tipográficas

Conclusión:

- Se confirma que no existen inconsistencias tipográficas ni fragmentación de datos en la categoría de interés. Esto simplifica el proceso de filtrado y asegura que el 100% de los registros de café serán incluidos en el análisis de la Región Andina sin necesidad de transformaciones previas en esta columna.

3.5. Verificación de Rango Temporal (Años)

Se inspeccionan los valores únicos de la columna 'Año' para descartar inconsistencias cronológicas o valores fuera de rango (como años futuros o valores en cero). Esto asegura que la evolución de la producción de café se analice sobre un periodo de tiempo válido.

Conclusión:

- Resultado: El dataset cubre el periodo [2019, 2020, 2021, 2022, 2023, 2024].
- Impacto: Los años son consistentes y no presentan valores nulos ni erróneos. Este rango permite realizar un análisis comparativo sólido de la producción de café.

4. Tipos de Datos

4.1. Transformación de Variables Numéricas

Durante la fase de exploración se identificó que las columnas métricas (Área, Producción y Rendimiento) presentaban un formato de texto debido al uso de separadores de miles (puntos) y decimales (comas).

Para habilitar el análisis estadístico, se aplicó el siguiente procedimiento:

- Limpieza de caracteres: Eliminación de puntos y sustitución de comas por puntos.

- Casting de tipos: Conversión de la serie de datos a tipo float64.

Conclusión: Adecuación de Datos Numéricos

- Acción: Se transformaron las columnas de producción de formato object a float.
- Resultado: Los datos quedaron normalizados bajo el estándar decimal de Python.
- Impacto: Esta transformación es la que permite generar el Resumen Estadístico y las visualizaciones posteriores, asegurando que los cálculos de media, desviación estándar y totales regionales sean exactos.

5. Valores Atípicos (Outliers)

Se realizó una inspección de las variables métricas para identificar valores que se alejan significativamente del promedio. En el contexto de la producción agrícola, un valor atípico no siempre es un error, sino que puede representar una zona de alta productividad.

Conclusión sobre valores atípicos

- Se identificaron valores atípicos en la variable de rendimiento mediante el uso de boxplots y el método del rango intercuartílico (IQR). Estos valores extremos generan una distribución sesgada, donde unos pocos registros presentan rendimientos muy altos en comparación con la mayoría. Sin embargo, al analizar los datos por tipo de cultivo, se evidenció que estos valores atípicos corresponden a cultivos con mayor productividad, como la caña, mientras que otros cultivos como el café presentan rendimientos más bajos y homogéneos. Por esta razón, los valores atípicos no se consideran errores y no fueron eliminados, ya que reflejan diferencias reales en la producción agrícola del país.

5.1 Distribución del Rendimiento Exclusivo del Café

Se realiza un análisis específico del cultivo de café con el objetivo de evaluar su rendimiento y compararlo con el comportamiento general del dataset.

Conclusión

El cultivo de café presenta una baja variabilidad en comparación con otros cultivos y no muestra valores atípicos extremos. Por esta razón, los datos se consideran consistentes y adecuados para el análisis, sin necesidad de eliminar registros.

6. Evaluación del Nivel de Granularidad

El dataset presenta información a nivel municipal y anual. Para este análisis, dicho nivel de detalle es mayor al necesario, por lo que se realizará una agregación de los datos a nivel departamental y regional para facilitar la comparación del rendimiento del café frente al promedio nacional.

6.1 Segmentación del Alcance (Filtrado)

Como complemento al ajuste de granularidad, se aplicó un filtrado del dataset para seleccionar únicamente los registros correspondientes al cultivo de café.

Justificación técnica:

Los cultivos agrícolas presentan rendimientos muy diferentes. Por esta razón, se filtró únicamente el café para evitar distorsiones en los promedios y obtener una comparación más precisa entre la Región Andina y el promedio nacional.

Limpieza y Transformación

Checklist de Limpieza y Preparación del Dataset

1. Corrección de Tipos de Datos (Casting):

- Convertir las columnas numéricas (Área Sembrada, Área Cosechada, Producción y Rendimiento) de tipo *object* (texto) a *float* (decimal).
- **Por qué:** Para poder realizar promedios, sumas y comparaciones matemáticas.

2. Tratamiento de Nulos Lógicos (Ceros Estructurales):

- Identificar y filtrar los registros que tienen **0.00** en producción y rendimiento.
- **Por qué:** Esos datos representan cultivos que no produjeron o se perdieron. Dejarlos bajaría el promedio de rendimiento de la Región Andina de forma irreal.

3. Estandarización de Variables Temporales:

- Convertir la columna Periodo a tipo *string* (texto).
- **Por qué:** Como vimos, algunos registros son años puros (2022) y otros tienen letras (2022A). Al estandarizarlos como texto, evitas errores de compatibilidad en Python.

4. Verificación de Redundancia:

- Mantener las columnas Año y Periodo tras comprobar que Periodo ofrece mayor detalle (semestres) que el Año.

- **Por qué:** Descubrimos que borrar Periodo nos haría perder información sobre la estacionalidad de los cultivos transitorios.

5. Diferenciación de Municipios: Resolución de Homonimia

- Implementar una columna de Ubicación Única.
- Esta variable concatena el nombre del municipio con su departamento respectivo, permitiendo diferenciar entidades territoriales con nombres idénticos.

6. Depuración de Columnas (Simplificación):

- Se eliminaron las columnas de Código **Dane departamento, Código Dane municipio y Código del cultivo.**
- Al contar ya con nombres estandarizados y una llave única de ubicación, estos códigos numéricos resultan redundantes.

7. Ajuste de Granularidad (Agregación):

- Crear una nueva columna de **Región** basada en la lista de departamentos.
- Agrupar los datos municipales para obtener totales departamentales y regionales.
- **Por qué:** Para que los gráficos no tengan miles de puntos ruidosos, sino que muestren claramente la comparación **Andina vs. Nacional.**

8. Filtrado por Cultivo de Interés:

- Crear un subconjunto de datos (DataFrame) que contenga exclusivamente el **Café.**

- **Por qué:** El análisis se centra en la eficiencia cafetera, por lo que trabajar con todo el dataset (maíz, arroz, etc.) solo genera ruido en los promedios.

Resultado de la preparación de datos

Se obtuvieron dos datasets listos para el análisis:

1. **df_limpio:** Es el resultado de la limpieza técnica (tipos de datos, eliminación de nulos y duplicados) de toda la base agrícola.

Contiene 135,608 registros de todos los cultivos y se utilizará para comparaciones generales.

2. **df_cafe:** Es el resultado de la segmentación estratégica (solo café y con la nueva columna de regiones) para responder a tu pregunta de investigación.

Contiene 3,771 registros exclusivos de café, siendo la base principal del estudio.

Estado de los datos

- Variables numéricas convertidas correctamente a tipo float.
- Clasificación regional (Region) integrada.
- Registros con valores en cero filtrados para mejorar la precisión del análisis.

Conclusión:

La preparación y limpieza de los datos permitió obtener datasets organizados, consistentes y adecuados para analizar el rendimiento del café y comparar el comportamiento de la Región Andina frente al promedio nacional.

Validación

1. Revisión de objetivos vs. dataset

El objetivo del estudio es analizar el rendimiento del café en la Región Andina frente al promedio nacional. Después del proceso de limpieza y transformación, el dataset `df_cafe` conserva las variables necesarias, como Año, Región, Rendimiento y Municipio, permitiendo realizar comparaciones geográficas y temporales.

2. Completitud de los datos

Se verificó que, después del filtrado de registros con valores en cero, no hubo pérdida de información relevante en los periodos analizados. Además, las variables necesarias para calcular el rendimiento promedio se encuentran completas en el dataset de café.

3. Relevancia de las variables

Las variables seleccionadas son adecuadas para el análisis. Rendimiento se utiliza como indicador principal de eficiencia productiva y Región permite realizar la comparación entre la Región Andina y el resto del país. También se eliminaron variables redundantes o poco relevantes para simplificar el análisis.

4. Granularidad adecuada

El dataset conserva el detalle por municipio y departamento, permitiendo analizar diferencias locales. Sin embargo, para responder la pregunta de investigación, se realizó una agrupación a nivel regional y anual, facilitando una comparación más clara del rendimiento del café frente al promedio nacional.

Anexos

1. **Acceso al Dataset:** El dataset utilizado en este proyecto puede consultarse en el siguiente enlace [Evaluaciones Agropecuarias Municipales \(EVA\)](#).
2. **Acceso al código fuente:** Se puede consultar el desarrollo técnico y la exploración de datos en el [Repositorio de GitHub - Proyecto Integrado III](#).
3. **Gestión del Proyecto:** Para la organización de tareas, asignación de responsabilidades y seguimiento del flujo de trabajo, se utiliza un tablero Kanban disponible en [Tablero de Trello - Gestión de Proyecto](#).

Conclusiones

- Se identificó que algunas variables numéricas como área sembrada, área cosechada, producción y rendimiento estaban almacenadas como tipo texto (object), debido a formatos con separadores de miles y decimales. Esto requirió un proceso de limpieza y conversión a valores numéricos para su correcto análisis.
- No se encontraron valores nulos ni registros duplicados en el dataset, lo que indica una buena consistencia en la estructura de los datos.
- El análisis estadístico mostró una alta variabilidad en la producción y el rendimiento agrícola entre municipios y departamentos, lo que refleja diferencias en las condiciones de producción y eficiencia agrícola en el país.
- Se encontró una relación fuerte entre el área sembrada y el área cosechada, lo que indica una alta efectividad en la cosecha. La producción presenta una relación moderada con el área cultivada, mientras que el rendimiento no depende del tamaño del área, sino de la eficiencia productiva del cultivo.
- La limpieza y transformación de los datos permitió mejorar la calidad del dataset, facilitando un análisis más preciso y confiable del rendimiento agrícola.
- Se identificó que las diferencias de rendimiento entre cultivos generan valores atípicos reales, por lo que fue necesario segmentar el análisis exclusivamente al cultivo de café.
- La creación de la variable Región y la agregación de datos facilitaron la comparación del comportamiento productivo de la Región Andina frente al promedio nacional.

Bibliografía

Ministerio de Agricultura y Desarrollo Rural. (2024). *Evaluaciones Agropecuarias Municipales - EVA 2019-2024*. Datos Abiertos Colombia. Recuperado de <https://www.datos.gov.co/Agricultura-y-Desarrollo-Rural/Evaluaciones-Agropecuarias-Municipales-EVA-2019-20/uejq-wxrr>